# МИНОБРНАУКИ РОССИИ САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ «ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА) Кафедра МО ЭВМ

### ОТЧЕТ

по лабораторной работе №5
по дисциплине «Искусственные нейронные сети»
Тема: Распознавание объектов на фотографиях

| Студент гр. 7382 | Гаврилов А.В. |
|------------------|---------------|
| Преподаватель    | Жукова Н.А.   |

Санкт-Петербург 2020

# Цель работы.

Распознавание объектов на фотографиях (Object Recognition in Photographs). CIFAR-10 (классификация небольших изображений по десяти классам: самолет, автомобиль, птица, кошка, олень, собака, лягушка, лошадь, корабль и грузовик).

### Порядок выполнения работы.

- 1. Ознакомиться со сверточными нейронными сетями.
- 2. Изучить построение модели в Keras в функциональном виде.
- 3. Изучить работу слоя разреживания (Dropout).

## Требования к выполнению задания.

- 1. Построить и обучить сверточную нейронную сеть.
- 2. Исследовать работу сеть без слоя Dropout.
- 3. Исследовать работу сети при разных размерах ядра свертки.

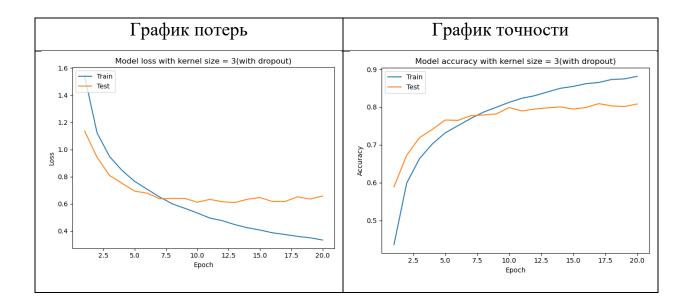
# Ход работы.

Была создана и обучена модель искусственной нейронной сети. Код предоставлен в приложении A.

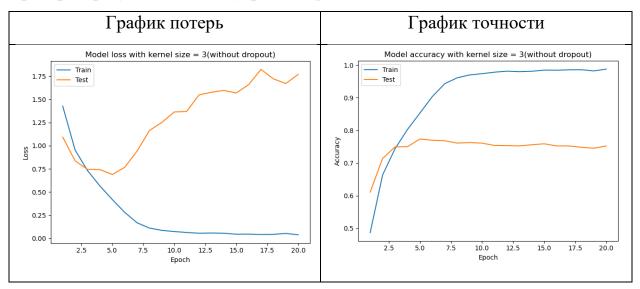
Архитектура созданной нейронной сети основана на модели из исходных данных к лабораторной работы и выставлены следующие параметры:

- Оптимизатор 'adam'
- Количество эпох обучения 20
- batch\_size = 80
- $pool\_size = 2*2$
- Ядро свертки: 3\*3

После обучения этой модели получили следующие результаты:

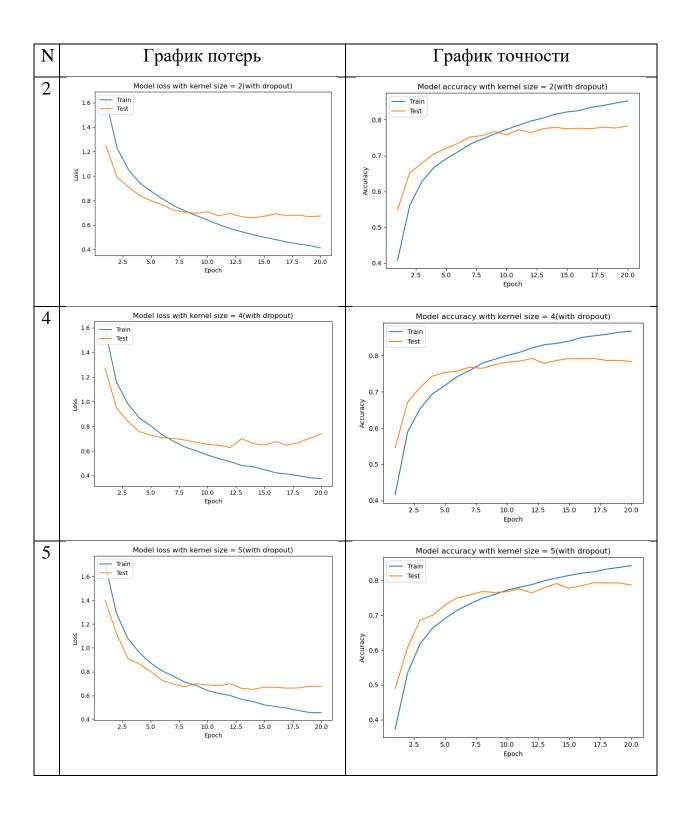


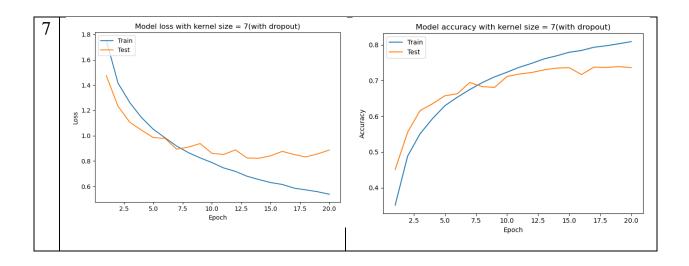
# Проверим результаты, если убрать dropout слой:



Как и ожидалось, модель стала переобучаться примерно на 6 эпохе. Таким образом справляются со своей задачей достаточно неплохо не давая сети переобучаться и сохраняя возможность сети к обобщению.

Исследуем модель при различных размерностях ядра свертки (с dropout слоями):





При изменении размера ядра свертки точность и потери сильно не изменяются и на процесс обучения это почти не повлияло. Но при размере ядра 7\*7 ошибка была наибольшей ~0.7 в сравнении с ~0.4-0.6 на остальных вариантах. Лучшей моделью оказался изначальный вариант с ядром 3\*3, точность которого ~0.85.

### Выводы.

В ходе работы была изучена задача классификация изображений из датасета CIFAR-10. Подобрана архитектура, дающая точность 85%. При исследовании влияния dropout слоев на модель, было доказано, что эти слои помогают при переобучении, неточности подобранных параметров и оставляют модели возможность к обобщению.

# ПРИЛОЖЕНИЕ А ИСХОДНЫЙ КОД ПРОГРАММЫ

# Файл main.py:

```
import gen data
from tensorflow.keras.layers import Input, Convolution2D,
MaxPooling2D, Dense, Dropout, Flatten
from tensorflow.keras.models import Model
import matplotlib.pyplot as plt
class Net:
   def __init__(self):
        self. set params()
        self.x_train, self.y_train, self.num_classes,
self.input shape, self.num train = gen data.get data()
    def __set_params(self):
        self.num epochs = 20
        self.batch size = 80
        self.pool size = (2, 2)
        self.conv depth 1 = 32
        self.conv depth 2 = 64
        self.drop prob 1 = 0.25
        self.drop prob 2 = 0.5
        self.hidden size = 512
    def build_model(self, kernel_size=3, hasDropout=True):
        inp = Input(shape=self.input shape)
        conv 1 = Convolution2D(self.conv depth 1, (kernel size,
kernel size),
                               padding='same', strides=(1, 1),
activation='relu')(inp)
        conv 2 = Convolution2D(self.conv depth 1, (kernel size,
kernel size),
                               padding='same',
activation='relu')(conv 1)
        pool 1 = MaxPooling2D(pool size=self.pool size)(conv 2)
        if hasDropout:
            drop 1 = Dropout(self.drop prob 1)(pool 1)
        else:
            drop 1 = pool 1
        conv 3 = Convolution2D(self.conv depth 2, (kernel size,
kernel size),
                               padding='same', strides=(1, 1),
activation='relu')(drop 1)
        conv 4 = Convolution2D(self.conv depth 2, (kernel size,
```

```
kernel size),
                               padding='same', strides=(1, 1),
activation='relu')(conv 3)
        pool 2 = MaxPooling2D(pool_size=self.pool_size)(conv_4)
        if hasDropout:
            drop 2 = Dropout(self.drop prob 1)(pool 2)
        else:
            drop_2 = pool_2
        flat = Flatten()(drop 2)
        hidden = Dense(self.hidden size, activation='relu')(flat)
        if hasDropout:
            drop 4 = Dropout(self.drop prob 2)(hidden)
        else:
            drop 4 = hidden
        out = Dense(self.num classes, activation='softmax')(drop 4)
        model = Model(inp, out)
        model.compile(loss='categorical crossentropy',
                      optimizer='adam',
                      metrics=['accuracy'])
        return model
    def plot(self, history, hasDropout, kernel size):
        if hasDropout:
            hasDropout = '(with dropout)'
        else:
            hasDropout = '(without dropout)'
        x = range(1, self.num epochs + 1)
        plt.plot(x, history.history['loss'])
        plt.plot(x, history.history['val loss'])
        plt.title('Model loss with kernel size = ' + str(kernel_size)
+ hasDropout)
        plt.ylabel('Loss')
        plt.xlabel('Epoch')
        plt.legend(['Train', 'Test'], loc='upper left')
        plt.show()
        plt.plot(x, history.history['acc'])
        plt.plot(x, history.history['val acc'])
        plt.title('Model accuracy with kernel size = ' +
str(kernel size) + hasDropout)
        plt.ylabel('Accuracy')
        plt.xlabel('Epoch')
        plt.legend(['Train', 'Test'], loc='upper left')
        plt.show()
    def lab5(self):
        model = self.build model()
        history = model.fit(self.x_train, self.y_train,
                            batch_size=self.batch_size,
epochs=self.num epochs,
                            verbose=1, validation split=0.1)
        self.plot(history, True, 3)
```

```
model = self.build model(hasDropout=False)
        history = model.fit(self.x train, self.y train,
                            batch size=self.batch size,
epochs=self.num epochs,
                            verbose=1, validation split=0.1)
        self.plot(history, False, 3)
        k \text{ size} = [2, 4, 5, 7]
        for i in k_size:
            model = self.build model(i)
            history = model.fit(self.x train, self.y train,
                            batch size=self.batch size,
epochs=self.num epochs,
                            verbose=1, validation split=0.1)
            self.plot(history, True, i)
lab = Net()
lab.lab5()
Файл gen data.pv:
from tensorflow.keras.datasets import cifar10
from keras.utils import to categorical
import numpy as np
def get data(size = None):
    (x_train, y_train), (x_test, y_test) = cifar10.load_data()
    num train, depth, height, width = x train.shape
    num_test = x_test.shape[0]
    num_classes = np.unique(y_train).shape[0]
    x train = x train.astype('float32')
    x test = x test.astype('float32')
    x train /= 255.0
    x test /= 255.0
    y_train = to_categorical(y_train, num_classes)
    y test = to categorical(y test, num classes)
    input shape = (depth, height, width)
    return x_train, y_train, num_classes, input_shape, num_train
```